



AI VIET NAM

@aivietnam.edu.vn

Design Validation

Khai-Trinh Xuan - TA
Hien-Ho Trong - STA



AI VIET NAM

@aivietnam.edu.vn

Outline

Introduction

Bias and Variance

Data Splitting Strategies

Model Validation Procedure



AI VIET NAM

@aivietnam.edu.vn

Outline

Introduction


Bias and Variance

Data Splitting Strategies

Model Validation Procedure


Introduction

❖ Machine Learning Life Cycle



Introduction

❖ Model Development





AI VIET NAM

@aivietnam.edu.vn

Outline

Introduction



Bias and Variance

Data Splitting Strategies

Model Validation Procedure

Bias and Variance


❖ Definition




Bias: sự sai khác giữa giá trị dự đoán của mô hình và giá trị thực tế.

Variance: là mức độ phân tán của các giá trị mà mô hình dự đoán so với các giá trị thực tế.

Bias and Variance




- Đường màu vàng biểu thị cho giá trị bias
- Đường màu xanh biểu thị cho giá trị variance
- Đường màu tím biểu thị độ lỗi tổng quát, thường được sử dụng trong quá trình testing



- Chúng ta giả sử rằng, những giá trị nằm ở trung tâm hình tròn là những giá trị ground truth.
- Những chấm tròn là những giá trị dự đoán của mô hình


Bias and Variance



Underfit: High Bias - Low Variance

Một mô hình quá đơn giản không thể biểu diễn được đặc trưng của bộ dữ liệu.


Ví dụ: Sử dụng mô hình Linear Regression để dự đoán giá nhà nhưng bộ dataset có đến ... 30 đặc trưng.



Hình tròn ngoài cùng bên trái:

- Giá trị dự đoán nằm gần nhau $\Rightarrow$ Low Variance
- Các giá trị dự đoán nằm xa tâm hình tròn $\Rightarrow$ High Bias (dự đoán sai nhiều)


Bias and Variance



Overfit: Low Bias - High Variance

Một model quá phức tạp, dẫn đến quá khớp (overfit) vào bộ data

Ví dụ: Sử dụng Polynomial Regression nhưng có độ degree quá lớn dẫn đến quá khớp vào bộ data. Đặc trưng là có kết quả rất tốt trên tập training nhưng tệ với tập test




Hình tròn ngoài cùng bên phải:

- Các giá trị dự đoán nằm xa nhau hơn $\Rightarrow$ High Variance
- Các giá trị dự đoán nằm gần tâm hình tròn hơn $\Rightarrow$ Low Bias

Bias and Variance

❖ Tradeoff



- Việc tìm ra sự cân bằng hợp lý bias và variance là rất quan trọng để xây dựng các mô hình có khả năng khái quát tốt với các dữ liệu mới.
- Có thể đạt được thông qua các kỹ thuật như cross-validation, regularization và chọn mô hình có độ phức tạp phù hợp.

Bias and Variance



Nếu mô hình sau huấn luyện có hiện tượng high bias thì nên làm gì ?

- Tăng thời gian huấn luyện.
- Tăng tính complexity của mô hình.



Nếu mô hình sau huấn luyện có hiện tượng high variance thì nên làm gì ?

- Tăng cường dữ liệu.
- Sử dụng các kỹ thuật regularization.
- Giảm tính complexity của mô hình.



AI VIET NAM

@aivietnam.edu.vn

Outline

Introduction


Bias and Variance

Data Splitting Strategies

Model Validation Procedure

Data Splitting Strategies

❖ Remind





Data Splitting Strategies

❖ Training vs Validation vs Test Set


	Training Set	Validation Set	Test Set
Mục đích	Huấn luyện mô hình	Chỉnh sửa hyperparameter và đánh giá hiệu suất mô hình trong quá trình huấn luyện	Đánh giá performance của mô hình đã hoàn thiện
Size	Phần lớn dữ liệu (60-80%)	Chiếm phần nhỏ 10-20%	Chiếm phần nhỏ 10-20%
Visibility	Mô hình được học trong quá trình huấn luyện.	Mô hình chỉ được học trong quá trình huấn luyện mô hình cuối cùng.	Mô hình không bao giờ được tiếp cận.

Keynote:

- Test set: chỉ dùng sau khi đã **hoàn tất quá trình xây dựng model để đánh giá performance của model**.
- Trong các competition, Test Set thường sẽ được giữ private và chúng ta chỉ được tiếp cận training và validation set.

Data splitting Strategies


❖ Random Splitting



Vấn đề ở đây là gì ?

Data Splitting Strategies


❖ K-fold Cross-Validation



Điều gì xảy ra nếu dữ liệu của chúng ta phân bố không đồng đều ?

Data Splitting Strategies

❖ Imbalanced Dataset




Vậy làm cách nào để giải quyết vấn đề này ?

Data Splitting Strategies

❖ Stratified K-fold Cross-Validation




❖ Stratified K-fold Cross-Validation - Step 1




Thực hiện Random Splitting trên từng group ta sẽ có phương pháp Stratified Splitting

Data Splitting Strategies

❖ Stratified K-fold Cross-Validation - Step 2




Create class K folds



Data Splitting Strategies


❖ Stratified K-fold Cross-Validation - Step 3




Bước cuối cùng: thực hiện thuật toán tương tự K-fold Cross-Validation

Data Splitting Strategies

❖ Monte-Carlo Cross-Validation



Iteration 1



Iteration 2



Iteration 3

...

Iteration 4



Data Splitting Strategies


❖ Keynote

Technique	Advantages	Disadvantages
Random Splitting	- Dễ implement và đánh giá.	- Có thể dẫn tới bias cao vào dữ liệu train.
Stratified Splitting	- Dễ implement và đánh giá. - Giảm bias vào dữ liệu train.	- Cần phải xác định và phân loại các group từ dữ liệu.
K-fold Cross-Validation	- Giảm bias vào dữ liệu train.	- Phức tạp và cần nhiều thời gian hơn Random Splitting. - Chỉ có thể xài cho lượng dữ liệu nhỏ.
Stratified K-fold Cross-Validation	- Duy trì mật độ phân bố của các group trong từng fold. - Sử dụng cho dữ liệu imbalance.	- Cần phải xác định và phân loại các group từ dữ liệu. - Chỉ có thể xài cho lượng dữ liệu nhỏ.
Monte-Carlo Cross-Validation	- Giảm tính performance variance của mô hình đánh giá.	- Có thể dẫn tới bias vào dữ liệu train như Random Splitting. - Cần nhiều thời gian. - Chỉ có thể xài cho lượng dữ liệu nhỏ.

Data Splitting Strategies

❖ Systematic Sampling

Chọn mẫu theo một khoảng cách nhất định đã được định trước.




Từ mẫu thứ 2, chọn các mẫu cách 3 đơn vị

Data Splitting Strategies

❖ Bootstrapping Sampling

Một phương pháp lấy mẫu ngẫu nhiên có thay thế (with replacement).
Chọn những mẫu hiện có để tạo thành bộ dữ liệu mới (có thể trùng lặp với nhau).





AI VIET NAM

@aivietnam.edu.vn

Outline


Introduction

Bias and Variance

Data Splitting Strategies

Model Validation Procedure

Model Validation Procedure



Nếu kết quả validation tốt nhưng kết quả test tệ thì có thể do những yếu tố nào ?



Nếu kết quả validation tốt nhưng kết quả test tệ thì có thể do những yếu tố nào ?

- Independence Assumption:
 - + Không nên có sự tương quan giữa dữ liệu trong tập train và tập val.
 - + Information Leakage
- Identically Distributed Assumption:
 - + Tất cả tập train, val và test nên có cùng một phân phối dữ liệu.
- Số lượng class phân loại của bộ dữ liệu đủ lớn để phân phối vào các fold (K-Fold Strategies)

Model Validation Procedure



Các kỹ thuật như Stratified sampling có thể sử dụng cho dạng dữ liệu Regression được không ?

Model Validation Procedure

Demo